



République Tunisienne

Ministère de l'Enseignement Supérieur et de la
Recherche Scientifique

Université de Monastir

Faculté des Sciences

Département de Physique



Rapport de Stage de Fin d'Etudes

pour l'obtention de

Diplôme de Licence en Électronique, Électrotechnique et Automatique

Spécialité : Système Embarqué

L S E
3

Sujet : **Système de reconnaissance de la langue des signes à base de
l'intelligence artificielle**

Élaboré par :

Soutenu le 07/06/2023 devant la Commission d'Examen composée de :

Président : Zied Gafsi

Rapporteur :

Encadrant : Wadhah Ayadi

Effectué à : **Faculté des Sciences de Monastir**

Laboratoire d'Electronique et Microélectronique(LR99ES30)

Année Universitaire 2022/2023

Dédicace

Je dédie ce projet

à mon père,

à ma mère,

à mon frère,

à ma sœur,

ainsi qu'à tous mes amis qui m'ont soutenu et aidé dans la réalisation de ce rapport. Votre amour, votre soutien et votre encouragement ont été précieux pour moi. Merci pour l'éducation, les principes et les valeurs que vous m'avez transmis.

Ce travail est dédié à vous tous.

Dédicace

Je dédie Ce projet là...

À mon père

Tu es pour moi l'ami le plus fidèle et le modèle de la combativité, Tu as toujours donné la meilleure de toi pour le bonheur de ta famille et tu nous as appris le sens de l'honneur ... Merci pour votre soutien et votre encouragements m'ont toujours donné la force pour prospérer dans la vie. Ce travail est le tiens ...

À ma mère

Pour votre soutien tout au long de mon parcours, pour m'avoir toujours fait confiance et avoir toujours trouvé les mots justes. Encouragements, pour avoir été attentive et disponible à chaque étape importante de ces 21 dernières années

Merci pour l'éducation, les principes et les valeurs que vous m'a avez transmis.

Je dédie aussi ce modeste travail

À mes frères et ma sœur

À mon ...

À ma grand-mère

À ...

À ...

À

À ...

À ...

À ...

À ...

À tous mes amies qui m'aident pour ce rapport vraiment un grand merci ...

Remerciements

Nous tenons à exprimer notre profonde gratitude envers les personnes qui ont joué un rôle essentiel dans la réalisation de cette étude. Leur soutien bienveillant a été inestimable et nous sommes incapables de trouver les mots justes pour décrire leur contribution. Nous leur adressons nos sincères remerciements du fond du cœur.

En premier lieu, nous sommes extrêmement reconnaissants envers notre encadrant, **M. Wadhah Ayadi**, qui nous a accordé cette opportunité et a cru en nous dès le début. Malgré les difficultés de ce stage, nous avons relevé le défi avec enthousiasme et avons respecté les délais grâce à votre soutien constant. Votre collaboration scientifique nous a permis de progresser et nous avons appris de vous, tant consciemment qu'inconsciemment, comment réaliser un travail de qualité. Nous apprécions énormément votre investissement en termes de temps et d'idées pour mener à bien ce projet.

Nous souhaitons également exprimer notre gratitude envers les membres du jury pour leur présence lors de cette soutenance, leur lecture attentive de notre rapport et leurs précieuses remarques. Nous remercions tout particulièrement **M. Sahbi** pour avoir pris le temps de lire notre rapport et pour ses commentaires constructifs. Enfin, nous tenons à remercier chaleureusement **M. Gafsi Zied** d'avoir accepté de présider ce jury, ce qui constitue un grand honneur pour nous.

Nous sommes sincèrement reconnaissants envers toutes ces personnes qui ont contribué à notre réussite et qui ont partagé leur expertise avec nous. Leur soutien indéfectible a été d'une valeur inestimable et nous les remercions du fond du cœur pour leur précieuse contribution à notre projet.

Guedim Abdessalem

Mohamed Amin Trabelssi

SOMMAIRE

Chapitre 1 : L'évolution de l'IA : un espoir pour les personnes en situation de handicap..

1	Introduction	3
2	L'intelligence Artificielle	3
3	Machine Learning	4
4	Deep Learning	5
4.1	Domaines d'applications	
4.2	Le neurone artificiel.....	
4.3	Les réseaux de neurones (NN).....	
4.4	Réseau de neurones convolutionels (CNN)	10
4.4.1	Couche convolutive	11
4.4.2	Couche de correction (Relu)	12
4.4.3	Couche de Pooling	13
4.4.4	Couche de fully-connected	14
5	Les fonctions d'activations	
6	Problématique	
7	Conclusion	

Chapitre 2 : Construire des Systèmes Intelligents : Apprentissage Profond, Réseaux Neuronaux et Reconnaissance des Gestes en Langue des Signe

1	Introduction	
2	Modèle proposé	
3	Modèle globale.....	
3.1	la phase de pré-traitement.....	
3.1.1	la base des données	
3.1.2	Fractionner la base de données.....	
3.1.3	Data Augmentation.....	
3.2	Model CNN	
4	Phase d'apprentissage	
4.1	Environnement utilisé	
4.2	Paramètres d'apprentissage	

5	Métriques d'évaluation
5.1	L'accuracy
5.2	Précision
5.3	Recall
5.4	F1-score
6	Résultats
7	Conclusion

Chapitre 3 : Développement pratique d'un système de reconnaissance des signes de la main.....

1.	Introduction
2.	Environnement matérielle utilisé
2.1	Carte Raspberry pi 4
2.2	L'architecture interne de carte Raspberry
2.3	premier démarrage de Raspberry
2.4	Caméra USB
3.	Réalisation réelle
4.	Conclusion

Table des figures

Figure 1 :	Relation entre IA, ML et DL
Figure 2 :	Différents types d'apprentissage automatique
Figure 3 :	structure de neurone artificiel
Figure 4 :	Architecture des réseaux de neurones artificiels
Figure 5 :	architecture du réseau de neurones convolutifs
Figure 6 :	Le principe du couche convolutif
Figure 7 :	la fonction de correction Relu

Figure 8 : principe du couche Pooling « Max Pooling ».....	
Figure 9 : principe du couche Pooling « Average-Pooling »	
Figure 10 : Le principe du couche fully connected.....	
Figure 11 : Le principe de l'apprentissage par transfert.....	
Figure 12 : Modèle globale.....	
Figure 13 : Quelques échantillons de bases de données.....	
Figure 14 : partitionnement de bases de données.....	
Figure 15 Architecture de resnet50v2.....	
Figure 16 : Perte et Précision du taux d'apprentissage (0.00001)	
Figure 17 : Perte et Précision du taux d'apprentissage (0.001)	
Figure 18 : Perte et Précision du taux d'apprentissage(0.0001).....	
Figure 19 : Perte et Précision du freezing layer (0)	
Figure 20 : Perte et Précision du freezing layer (-10)	
Figure 21 : Perte et Précision du freezing layer (-20)	
Figure 22 : Perte et Précision du batch size (8)	
Figure 23 : Perte et Précision du batch size (16)	
Figure 24 : Perte et Précision du batch size (32)	
Figure 25 : Précision et Perte du modèle en 5 époque.....	
Figure 26 : Précision et Perte du modèle en 10 époque.....	
Figure 27 : Précision et Perte finale	
Figure 28 : Matrix de confusion.....	
Figure 29 : Matérielles utilisés	
Figure 30 : Carte Raspberry pi 4	
Figure 31 : l'architecture interne de la carte Raspberry pi 4.....	
Figure 32 : Raspberry pi Imager	
Figure 33 : L'ajout de ssh	
Figure 34 : L'ajout de IP du Rasperry	
Figure 35 : L'ajout de IP de Ethernet	
Figure 36 : Branchement de carte Raspberry	
Figure 37 : L'interface de Putty	
Figure 38 : L'interface de VNC Viewer	
Figure 39 : Desktop du carte Raspberry	
Figure 40 : Test de reconnaissance des gestes.....	

Liste de tableaux

Tableau 1 : Les fonctions d'activations.....

Tableau 2 : Les bibliothèques installées.....

Tableau 3 : les caractéristiques de Raspberry pi 4

Introduction Générale

Le nombre de personnes handicapées dans le monde augmente constamment. Selon l'Organisation mondiale de la santé, plus d'un milliard de personnes, soit environ 15% de la population mondiale, vivent avec un handicap. Ces personnes sont confrontées à de nombreux problèmes, notamment en termes d'accessibilité, de discrimination et d'exclusion sociale. Les personnes handicapées ont également des difficultés à accéder aux services de santé, à l'éducation, à l'emploi et à la participation à la vie sociale.

L'intelligence artificielle (IA) a connu une évolution spectaculaire au cours des dernières années. Les avancées technologiques ont permis d'utiliser l'intelligence artificielle pour résoudre de nombreux problèmes complexes, y compris ceux liés aux personnes handicapées. Par exemple, l'intelligence artificielle peut être utilisée pour créer des applications et des outils qui aident les personnes malvoyantes à naviguer dans leur environnement, ou pour développer des dispositifs de communication pour les personnes sourdes ou muettes.

Dans cette présentation, nous allons nous concentrer sur la façon dont l'intelligence artificielle peut aider les personnes sourdes et muettes. Nous allons explorer les différentes technologies disponibles pour améliorer leur communication, y compris les applications de traduction de la langue des signes et les outils de synthèse vocale. Notre objectif est de sensibiliser à l'importance de l'accessibilité et de montrer comment l'intelligence artificielle peut être utilisée pour aider à résoudre certains des problèmes rencontrés par les personnes sourdes et muettes.

Chapitre 1 :

**L'évolution de l'Intelligence Artificielle : un espoir pour les personnes
en situation de handicap**

1. Introduction

Ce chapitre se divise en trois parties distinctes. La première partie a pour objectif d'expliquer le concept d'intelligence artificielle. La partie suivante est consacrée à la présentation des différentes catégories d'apprentissage automatique. Enfin, nous aborderons l'apprentissage profond, également appelé "Deep Learning" ou DL, en présentant ses bases et ses principes fondamentaux. Nous exposerons ensuite la problématique à laquelle notre travail se propose de répondre et nous présenterons notre solution. Enfin, une conclusion viendra clôturer cette présentation.

2. L'intelligence Artificielle

Les techniques d'intelligence artificielle désignent les méthodes par lesquelles les machines, comme les ordinateurs, sont capables de penser et d'appliquer la logique comme le font les êtres humains, par exemple la reconnaissance vocale, la résolution de problèmes, etc. Les techniques de traitement d'image sont les méthodes permettant d'améliorer la qualité de l'image et d'en extraire des informations. Lorsque l'intelligence artificielle est appliquée aux techniques de traitement d'image, diverses applications telles que la détection de visage, la reconnaissance de motifs, etc., peuvent être utilisées. [1].

Dans le domaine de la reconnaissance de la langue des signes basée sur l'intelligence artificielle, il est essentiel de comprendre les différentes branches de l'intelligence artificielle, notamment l'apprentissage automatique (Machine Learning ou ML) et l'apprentissage profond. Bien que ces domaines soient étroitement liés, il existe des différences significatives entre eux. Comme la figure ci-dessous l'illustre :




Figure 1 : Relation entre intelligence artificielle, apprentissage automatique et apprentissage profond

3. Apprentissage Automatique

L'apprentissage automatique est une approche de l'intelligence artificielle qui repose sur des algorithmes détectant de manière autonome des motifs et des corrélations dans les données, afin de construire un modèle pouvant être utilisé pour prédire des données non vues. Cette approche est très flexible et peut être utilisée pour aborder une grande variété de tâches. Bien que les systèmes apprennent de manière autonome à partir des données, une expertise humaine est toujours nécessaire pour choisir une tâche, collecter les données requises, construire et évaluer un modèle, et l'intégrer dans un flux de travail. [2]. Pour illustrer nos résultats de manière visuelle, nous avons préparé la Figure [2] :




Figure 2 : les Différents types d'apprentissage automatique

Comme le montre cette image, l'apprentissage automatique a différents types, tels que :

- **Apprentissage supervisé** : Un type d'apprentissage automatique où un modèle est entraîné sur un ensemble de données étiquetées, c'est-à-dire des données avec des réponses connues. Le modèle utilise ces exemples pour apprendre à prédire les étiquettes de nouvelles données similaires.
- **Apprentissage non supervisé** : Un type d'apprentissage automatique où un modèle est entraîné sur un ensemble de données non étiquetées. Le modèle explore les structures et les schémas intrinsèques des données pour regrouper, catégoriser ou extraire des informations utiles sans la présence d'étiquettes.
- **Apprentissage semi-supervisé** : Un type d'apprentissage automatique qui combine des données étiquetées et non étiquetées pour l'entraînement d'un modèle. Les données étiquetées sont utilisées pour guider l'apprentissage du modèle, tandis que les données non étiquetées aident à exploiter davantage les informations non supervisées.
- **Apprentissage par renforcement** : Un type d'apprentissage automatique où un agent apprend à prendre des décisions en interagissant avec un environnement. L'agent

effectue des actions et reçoit des récompenses ou des pénalités en fonction de ses performances. Il ajuste ensuite sa stratégie pour maximiser les récompenses au fil du temps.

4. Apprentissage Profond :

L'apprentissage profond est une branche en plein essor de l'apprentissage automatique. Il s'agit d'une approche qui vise à détecter des motifs complexes à partir de grandes quantités de données. L'apprentissage profond utilise des techniques avancées pour créer des modèles abstraits et effectuer des transformations non linéaires sur ces données. Ces modèles sont capables de reconnaître des schémas et des caractéristiques à différents niveaux de détail. Grâce aux progrès technologiques récents, l'apprentissage profond connaît une croissance rapide et offre des opportunités passionnantes pour résoudre divers problèmes et obtenir de nouvelles connaissances à partir des données. [3]

4.1 Domaines d'applications :

L'apprentissage profond a révolutionné la classification d'images en proposant des méthodes précises et efficaces pour reconnaître et interpréter les motifs visuels. Grâce à ces avancées, les machines sont désormais capables de comprendre et d'analyser le contenu visuel qui les entoure de manière plus précise et sophistiquée.

4.2 Le neurone artificiel :

Le neurone formel est un modèle mathématique. Il est utilisé dans la recherche en intelligence artificielle, principalement en association avec d'autres neurones formels pour former un réseau de neurones. Il contient plusieurs formules mathématiques afin de reproduire le plus fidèlement possible la fonction des neurones aux entrées différentes (dendrites), leur importance (coefficients de pondération) et leurs sorties (axones) et ainsi comprendre son potentiel d'interaction avec les autres neurones. [4]. Afin de mieux appréhender les tendances que nous avons observées, examinons maintenant la Figure [3] :




Figure 3 : structure de neurone artificiel

4.3 Les réseaux de neurones (NN) :

Les réseaux de neurones utilisent des automates (neurones formels) pour simuler les fonctions des cellules nerveuses. Un réseau de neurones se compose d'un groupe de neurones (nœuds) qui sont connectés les uns aux autres par des liens qui propagent des signaux d'un neurone à l'autre. En raison de leur capacité à apprendre, les réseaux de neurones permettent de découvrir des relations non linéaires complexes entre un grand nombre de variables sans intervention externe. De ce fait, ils sont largement utilisés pour de nombreux problèmes de classification (objectifs marketing, reconnaissance de formes, traitement du signal, etc.), d'estimation (modélisation de phénomènes complexes, etc.) et de prévision (bourse, ventes, etc.). [5] Au fur et à mesure que nous approfondissons notre analyse, nous pouvons nous référer à la Figure [4] comme support visuel :




Figure 4 : Architecture des réseaux de neurones artificielles

4.4 Réseau de neurones convolutionnels (CNN) :

Le CNN est une classe de méthodes d'apprentissage en profondeur qui est devenue dominante dans différents domaines de vision informatique. Les CNN sont largement utilisés dans les problèmes d'image et de reconnaissance d'image car ils présentent plusieurs avantages par rapport à d'autres technologies. Les CNN sont un type de réseau de neurones spécialisé dans le traitement des données et sont actuellement considérés comme les modèles les plus performants pour la classification des images. [6] Pour mieux comprendre le sujet, dirigeons notre attention vers la Figure [5] :




Figure 5 : architecture du CNN

Dans le contexte des CNN pour la classification d'images, différents types de couches sont utilisés. Ces couches jouent un rôle clé dans l'extraction des caractéristiques visuelles.

4.4.1 Couche convolutive :

Comme son nom l'indique, la couche de convolution joue un rôle important dans le fonctionnement des CNN. Elle constitue l'unité fondamentale d'un CNN pour la plupart des calculs effectués. Les paramètres de la couche se concentrent sur l'utilisation de noyaux d'apprentissage. Ces noyaux sont généralement de petite dimension spatiale, mais se déploient sur toute la dimension de profondeur de l'entrée. Lorsque les informations atteignent une couche de convolution, celle-ci convole chaque filtre sur la dimension spatiale des données pour fournir une carte d'activation en 1D. [7] Afin de fournir une représentation visuelle du concept abordé, nous avons inclus la Figure [6] :




Figure 6 : Le principe du couche convolutif

4.4.2 Couche de correction (Relu) :

Rectified Linear Units (ReLU) est une fonction d'activation, qui repose sur des fondements biologiques et mathématiques solides. En 2011, il a été démontré que cette fonction améliorait davantage l'apprentissage des réseaux neuronaux profonds. Elle fonctionne en seuillant les valeurs à zéro, c'est-à-dire $f(x) = \max(0, x)$. En d'autres termes, elle renvoie 0 lorsque $x < 0$, et inversement, elle renvoie une fonction linéaire lorsque $x \geq 0$. Voir la Figure 1 pour une représentation visuelle. [8] Avant d'approfondir notre analyse, observons la Figure [7].




Figure 7 : la fonction de correction Relu

4.4.3 Couche de Pooling :

Les opérations de pooling réduisent les dimensions des cartes de caractéristiques en utilisant certaines fonctions pour résumer les sous-régions, telles que prendre la valeur commune ou la valeur maximale. Les couches de pooling visent à réduire progressivement la dimensionnalité

des données, ce qui permet également de réduire le nombre de paramètres et la complexité du modèle, tout en contrôlant le problème de surajustement. Certaines des opérations de pooling courantes sont le max pooling et l'average pooling.[9]

Le max pooling divise la carte de caractéristiques en plusieurs sous-sections, réduisant ainsi la taille dans de nouvelles sous-sections, puis choisit la valeur maximale de la carte de caractéristiques. La figure 8 montre le fonctionnement de max pooling.




Figure 8 : principe du couche Pooling « Max Pooling »

Le même principe s'applique à la sélection de l'average pooling, mais ce type de couche choisira la valeur moyenne de la carte de caractéristiques pour pouvoir récupérer toutes les informations de l'image. La figure 9 montre le fonctionnement de Average-Pooling. [10]




Figure 9 : principe du couche Pooling « Average-Pooling »

En résumé, le Pooling réduit la taille des cartes de caractéristiques en conservant les valeurs maximales. Il permet de synthétiser les informations importantes et d'améliorer l'efficacité des calculs ultérieurs dans le réseau neuronal.

4.4.4 Couche de fully-connected :

Dans un CNN typique, les couches entièrement connectées (fully-connected layers) jouent un rôle important dans l'extraction des caractéristiques globales des données, mais toutes ces caractéristiques globales ne sont pas forcément utiles, notamment en présence de données bruitées. De plus, les couches entièrement connectées représentent la majorité des paramètres totaux du modèle. Les nombreux paramètres des couches entièrement connectées peuvent contribuer au problème de surajustement (overfitting). [11] Pour mieux apprécier les résultats obtenus, examinons attentivement la Figure [10] :




Figure 10 : Le principe du couche fully-connected

4.4.5 La couche "flatten" (aplatissement)

La couche "flatten" dans un CNN transforme les données d'entrée en un vecteur unidimensionnel, essentiel pour les couches suivantes. Elle permet de passer des caractéristiques spatiales aux caractéristiques linéaires, simplifiant ainsi leur manipulation. Cette opération conserve les informations tout en les organisant de manière linéaire. En résumé, la couche "flatten" joue un rôle crucial en facilitant la transition entre les étapes de convolution et les étapes de classification ou de prédiction finales. La Figure [11] constitue une ressource visuelle essentielle pour comprendre la couche "flatten" .




Figure 11 : Le principe du couche "flatten"

4.4.6 Les fonctions d'activations :

Le tableau ci-dessous présente les fonctions d'activation :

Tableau 1 : Les fonctions d'activations

Fonction	Equation	Description
Sigmoïde	$A(z) = (1 - z) / (1 + e)$	La fonction sigmoïde est une fonction d'activation couramment utilisée dans les réseaux de neurones. Elle normalise les valeurs des données entre 0 et 1 et attribue des probabilités aux données. Cependant, la somme des probabilités peut différer de 1.
Soft max	$A(z) = \frac{ke^{je^zk}}{\sum_{k=1}^J e^{\epsilon \{1 \dots k\}}}$	La fonction Softmax, est une fonction d'activation utilisée dans les réseaux de neurones pour la classification multiclasse. Elle attribue des probabilités aux différentes classes en normalisant les valeurs exponentielles des entrées. Cela permet d'obtenir une distribution de probabilités où la somme de toutes les probabilités est égale à 1.

5. Problématique :

Les personnes en situation de handicap, spécialement celles qui sont confrontées à des troubles de communication, se heurtent à d'énormes défis lorsqu'il s'agit d'interagir avec les autres. Certaines conditions ou limitations peuvent empêcher ces individus d'établir une communication fluide et efficace.

En Tunisie, il existe une proportion importante de personnes qui rencontrent des difficultés à communiquer en raison de handicaps divers. Ces handicaps peuvent être physiques, sensoriels, cognitifs ou liés à des troubles du développement. La communication joue un rôle fondamental

dans la vie quotidienne, notamment dans les interactions sociales, l'accès à l'éducation et aux soins de santé, ainsi que dans l'exercice des droits et des responsabilités civiques.

Cependant, il est essentiel de reconnaître que chaque personne est unique et que les besoins en matière de communication peuvent varier considérablement. Certains individus peuvent nécessiter des aides techniques telles que des dispositifs de communication augmentée et alternative (CAA) pour faciliter leur expression et leur compréhension. D'autres peuvent utiliser des langues des signes ou des systèmes de communication spécifiques pour compenser leurs difficultés de parole.

Malheureusement, malgré les progrès réalisés dans le domaine de la technologie et de la linguistique appliquée, il subsiste encore des lacunes importantes dans l'accessibilité et le soutien à la communication pour les personnes en situation de handicap en Tunisie.

Cela soulève des questions essentielles : comment améliorer l'accessibilité et les opportunités de communication pour ces individus ? Quelles sont les stratégies et les technologies émergentes, telles que la traduction automatique, l'intelligence artificielle et les interfaces cerveau-ordinateur, qui pourraient contribuer à surmonter ces obstacles ?

En explorant ces problématiques, nous pourrions ouvrir la voie à des avancées significatives dans l'inclusion et la participation des personnes en situation de handicap dans tous les aspects de la société. En mettant l'accent sur la recherche, le développement de politiques et de solutions adaptées, nous pouvons espérer offrir des opportunités égales de communication et de participation à tous, indépendamment de leurs différences et de leurs handicaps.

6. Conclusion :

Dans ce chapitre, nous avons abordé les principes fondamentaux de l'apprentissage automatique et l'apprentissage en profondeur. Nous avons examiné son application aux réseaux neuronaux en analysant leurs performances et les algorithmes utilisés. De plus, nous avons identifié certains défis auxquels sont confrontés les développeurs, ainsi que des solutions et des recommandations prometteuses.

Dans le chapitre suivant, nous nous concentrons sur l'application de l'apprentissage en profondeur à notre projet spécifique, à savoir les modèles de réseaux neuronaux artificiels. Nous examinons en détail leurs architectures et les configurations nécessaires pour assurer leur bon fonctionnement. Nous présentons également une démonstration du modèle CNN utilisé pour la reconnaissance des gestes en langue des signes. Enfin, nous expliquons les métriques

que nous avons implémentées, notamment la métrique personnalisée "Metric_Evaluation", qui nous donne un aperçu des performances de nos modèles.

Chapitre 2 :

Apprentissage Profond et Langue des Signes

1. Introduction

Ce chapitre se concentre sur la création d'un système de reconnaissance de la langue des signes à base de l'intelligence artificielle. Nous examinons les défis liés à la sélection des paramètres et à l'architecture optimale des modèles, ainsi que les résultats obtenus grâce à nos expérimentations. Notre objectif est de proposer une solution performante et précise pour faciliter l'interaction et la communication dans la langue des signes.

2. Modèle proposé

Dans notre projet, nous avons consacré des efforts considérables à explorer divers modèles pré-entraînés renommés afin de trouver la solution optimale. Au cours de cette exploration, nous avons évalué et comparé plusieurs modèles tels que VGG16, ResNet, Inception, et bien d'autres. Chaque modèle a été entraîné et testé avec rigueur, en analysant leurs performances en termes de précision, d'efficacité et de capacité de généralisation.

Dans cette démarche, nous avons utilisé une technique appelée "apprentissage par transfert". L'apprentissage par transfert consiste à exploiter les connaissances et les représentations acquises par un modèle pré-entraîné sur une tâche ou un domaine similaire pour améliorer l'apprentissage et la performance sur notre tâche spécifique. Avant de passer à l'étape suivante, concentrons-nous sur la Figure [12] :



Figure 12 : Le principe de l'apprentissage par transfert

Cette approche nous permet de tirer parti des connaissances préalablement acquises par le modèle pré-entraîné, réduisant ainsi la nécessité de tout entraîner depuis le début.

Après une analyse approfondie des résultats, nous avons choisi ResNet50v2 comme modèle privilégié en raison de son architecture avancée, de ses performances élevées et de sa précision supérieure.

3. Modèle globale :

La figure ci-dessous présente de manière claire et compréhensible l'architecture globale de notre modèle proposé. Ce modèle est composé de différentes parties qui jouent un rôle essentiel dans le processus. La première partie est la phase de pré-traitement où nous travaillons avec la base de données. Cela comprend des étapes telles que l'augmentation des données, qui permet d'élargir et de diversifier notre ensemble de données, ainsi que la division de la base de données pour les différentes phases de l'apprentissage. Ensuite, nous passons à la

normalisation des images. Cette étape vise à mettre les images dans un format standardisé, ce qui facilite le traitement ultérieur.

Enfin, la partie centrale de notre modèle est le CNN. Nous avons choisi l'architecture ResNet50V2, reconnue pour ses performances élevées dans la vision par ordinateur. Ce réseau est responsable de l'extraction des caractéristiques des images et de la prise de décision.

En combinant toutes ces parties, notre modèle fonctionne de manière cohérente pour fournir des résultats précis et fiables. Dans le but d'enrichir notre compréhension du sujet, analysons la Figure [13] :




Figure 13 : Modèle globale

3.1 la phase de pré-traitement

3.1.1 la base des données

Pour augmenter la précision et améliorer la performance du modèle, nous avons utilisé l'intégralité de la base de données HaGRID (HAnd Gesture Recognition Image Dataset) pour l'entraînement. Cette base de données comprend un total de 10 380 images RGB en Full HD, réparties en 6 classes de gestes : "peace", "stop", "call", "palm", "ok" et "mute". Les sujets inclus dans la base de données ont des tranches d'âge allant de 18 à 65 ans. Les images ont été capturées principalement en intérieur, avec une variation significative des conditions d'éclairage, incluant à la fois la lumière artificielle et naturelle. La base de données comprend également des images prises dans des conditions extrêmes, telles que des sujets faisant face ou tournant le dos à une fenêtre. Les sujets ont effectué les gestes à des distances allant de 0,5 à 4 mètres de la caméra.

Pour notre projet, nous avons utilisé l'ensemble de ces données pour entraîner notre modèle. Cela nous permet de couvrir l'ensemble des gestes et des variations présentes dans la base de données, afin d'obtenir une reconnaissance des gestes précise et performante. En adaptant notre modèle à ces six classes de gestes spécifiques et en utilisant l'intégralité de la base de données HaGRID, nous visons à obtenir les meilleurs résultats possibles en termes de précision et de

performance dans la reconnaissance des gestes. Afin de fournir une représentation visuelle du concept abordé, nous avons inclus la Figure [14] :




Figure 14 : Quelques échantillons de bases de données

3.1.2 Fractionner la base de données

Pour diviser notre base de données de 11 380 images, nous avons suivi une approche bien définie. L'ensemble d'entraînement a été alloué à 79,24% du total, soit 8 280 images, avec une moyenne de 1 380 images par classe. L'ensemble de validation, quant à lui, représentait 20,21% du total, avec 2 100 images réparties équitablement, soit 350 images par classe. Enfin, nous avons réservé 11,55% de la base de données, soit 1 200 images, pour l'ensemble de test, avec 200 images pour chaque classe. Pour mieux comprendre le sujet, dirigeons notre attention vers la Figure [15] :




Figure 15 : partitionnement de bases de données

3.1.3 Data Augmentation

Nous avons procédé à plusieurs essais en explorant différentes valeurs afin d'optimiser les performances de notre modèle. Après plusieurs itérations, nous avons retenu les valeurs finales qui ont donné les résultats les plus satisfaisants.

Pour améliorer les performances du modèle, nous avons utilisé des techniques d'augmentation de données. Dans le dossier d'entraînement, nous avons appliqué des augmentations telles que la rotation, le décalage horizontal et vertical, la transformation de cisaillement, le zoom et le retournement horizontal des images. Ces techniques permettent d'accroître la variabilité des exemples d'entraînement, ce qui aide le modèle à mieux généraliser et à être plus résistant face à des variations dans les données réelles. Nous avons également appliqué les mêmes techniques d'augmentation de données dans le dossier de validation. Cela permet d'obtenir une évaluation plus fiable du modèle en exposant celui-ci à des variations similaires à celles qu'il rencontrera dans des données inédites.

En utilisant les générateurs d'images avec les paramètres d'augmentation spécifiés, nous avons entraîné notre modèle en exploitant des données enrichies. Cette approche nous a permis d'améliorer la capacité de notre modèle à généraliser et à s'adapter à de nouvelles images.

3.2 Model CNN :

La décision de choisir RasNet50V2 pour notre projet de reconnaissance de la langue des signes repose sur plusieurs facteurs qui en font un choix adapté. Tout d'abord, RasNet50V2 a démontré d'excellentes performances dans des tâches de classification d'images, y compris des tâches complexes de reconnaissance visuelle. Ce modèle a été entraîné sur de vastes ensembles de données d'images et a obtenu une précision élevée dans divers benchmarks. En exploitant les poids pré-entraînés et les représentations apprises, nous pouvons bénéficier de la capacité du modèle à extraire des caractéristiques visuelles significatives à partir des gestes de la langue des signes. Au fur et à mesure que nous approfondissons notre analyse, nous pouvons nous référer à la Figure [16] comme support visuel.




Figure 16 : Architecture de resnet50v2

Dans notre architecture de modèle, nous avons 5 étapes. Au premier stage, l'entrée passe par une couche de convolution suivie d'une normalisation et d'une couche ReLU. Ensuite, une opération de max pooling est effectuée pour réduire la dimensionnalité.

Aux étapes 2, 3, 4 et 5, il y a des blocs de convolution et des blocs d'identité. Chaque bloc comprend 3 couches de convolution qui permettent d'extraire des caractéristiques plus complexes à mesure que les données progressent dans le réseau. Ces étapes supplémentaires améliorent la capacité du modèle à reconnaître les motifs spécifiques de la langue des signes. Enfin, il y a une opération de pooling moyenne pour réduire la taille des caractéristiques extraites, suivie d'une étape de mise en forme (flatten). Ensuite, les données sont alimentées dans une couche entièrement connectée.

4. Phase d'apprentissage

4.1 Environnement utilisé

Python est un langage de programmation populaire et polyvalent, réputé pour sa simplicité, sa lisibilité et sa large communauté de développeurs. Il est couramment utilisé dans le domaine de l'intelligence artificielle grâce à ses bibliothèques et frameworks spécialisés, tels que TensorFlow et PyTorch, qui facilitent le développement de modèles d'apprentissage automatique. Google Colab est une plateforme cloud offrant un environnement de développement intégré pour Python, ce qui permet la création, l'exécution et le partage de notebooks Jupyter. Grâce à Google Colab, il est possible d'accéder gratuitement à des ressources de calcul puissantes comme les GPU et les TPU, ce qui accélère significativement l'entraînement des modèles d'intelligence artificielle. Dans notre projet, l'utilisation de Python et de Google Colab a été d'une grande aide pour développer et expérimenter nos modèles de manière plus efficace. Voici les bibliothèques utilisées dans notre modèle :

Tableau 2 : Les bibliothèques installées

Bibliothèque	Définition
Tensorflow	Une bibliothèque d'apprentissage automatique populaire et puissante pour la création de modèles d'IA.
Numpy	Une bibliothèque fondamentale pour le calcul numérique en Python, utilisée pour manipuler les tableaux et effectuer des opérations mathématiques.
Opencv	Une bibliothèque spécialisée dans le traitement d'images et la vision par ordinateur, utilisée pour la manipulation et l'analyse d'images dans notre modèle.
Pandas	Une bibliothèque pour la manipulation et l'analyse des données, offrant des structures de données puissantes et une grande variété de fonctions.

4.2 Paramètres d'apprentissage

Dans notre code, nous avons 4 paramètres d'apprentissage importants qui ont un effet direct sur la précision et la perte du modèle. Tout d'abord, la taille du lot (batch size) est importante car elle détermine le nombre d'échantillons utilisés dans chaque itération de l'apprentissage. Une taille de lot plus grande peut accélérer le processus d'apprentissage, mais peut également nécessiter plus de mémoire. Ensuite, l'époque (epoch) fait référence au nombre de fois où l'ensemble des données est parcouru lors de l'apprentissage. Une valeur plus élevée peut permettre au modèle de mieux généraliser, mais peut également augmenter le temps d'apprentissage.

Ensuite, nous avons les couches pré-entraînées que nous figeons. La mise en veille des couches, ou figer les couches, désigne la technique de désactiver certaines couches d'un modèle pré-entraîné pendant le réglage fin. Cela permet de conserver les poids pré-entraînés et les capacités d'extraction de caractéristiques du modèle de base, tout en ajustant les couches finales pour la tâche spécifique. Cette approche combine les avantages de l'apprentissage préalable avec une personnalisation ciblée pour obtenir de meilleures performances.

Enfin, le taux d'apprentissage (learning rate) joue un rôle crucial. Il détermine la taille des ajustements effectués sur les poids du modèle à chaque mise à jour. Un taux d'apprentissage trop élevé peut entraîner une instabilité du modèle, tandis qu'un taux trop faible peut ralentir le

processus d'apprentissage. Trouver un bon équilibre est essentiel pour obtenir de bons résultats. Voir les figures ci-dessous :

- **Le taux d'apprentissage:**

Dans cette figure, nous avons testé les taux d'apprentissage de 0,00001, 0,0001 et 0,001. Nous avons remarqué que les variations d'exactitude et de perte n'étaient pas significatives. Par conséquent, nous avons opté pour un taux d'apprentissage de 0,0001, qui est généralement considéré comme un bon point de départ et fonctionne souvent bien pour de nombreuses tâches d'apprentissage profond.




Figure 17 : Perte et Précision du taux d'apprentissage (0.0001)




Figure 18 : Perte et Précision du taux d'apprentissage (0.001)




Figure 19 : Perte et Précision du taux d'apprentissage (0.00001)

- **Freezing layer :**

Dans cette figure, nous avons modifié la mise en veille des couches en passant de 0 à 30, puis à 60. Nous avons observé une augmentation de l'exactitude, mais le modèle a pris beaucoup plus de temps au-delà de 60. C'est pourquoi nous avons choisi de figer les couches à 60, afin d'obtenir un compromis entre l'exactitude et le temps d'exécution du modèle.




Figure 20 : Perte et Précision du freezing layer (0)




Figure 21 : Perte et Précision du freezing layer (-10)




Figure 22 : Perte et Précision du freezing layer (-20)

- **Batch size :**

Dans cette étude, nous avons testé différentes tailles de batch, notamment 8, 16 et 32. Nous avons observé que l'exactitude et la perte variaient considérablement en fonction de la taille du batch. Après plusieurs expérimentations, nous avons constaté que la taille de batch de 8 offrait les meilleures performances en termes d'exactitude et de perte. Cette taille de batch plus petite

a permis au modèle de mieux généraliser et d'obtenir des résultats plus précis. Par conséquent, nous avons sélectionné une taille de batch de 8 comme choix final pour notre modèle de détection des signes de main, car elle a montré les meilleures performances dans notre cas spécifique.




Figure 23 : Perte et Précision du batch size (8)




Figure 24 : Perte et Précision du batch size (16)




Figure 25 : Perte et Précision du batch size (32)

- **l'époque :**

Dans notre analyse, nous avons entraîné notre modèle de détection des signes de main sur différents nombres d'époques : 5, 10 et 20. Après avoir évalué les performances, nous avons constaté que le modèle atteignait sa meilleure précision après 20 époques. Cependant, nous avons observé un phénomène de surapprentissage à partir de la fin de la 17e époque, ce qui

s'est traduit par une diminution de la précision sur les données de test. Malgré cela, la performance globale était encore supérieure après 20 époques, ce qui justifie notre choix de ce nombre d'époques comme étant optimal.




Figure 26 : Précision et Perte du modèle en 5 époque




Figure 27 : Précision et Perte du modèle en 10 époque

Après avoir mené différentes expérimentations, nous avons constaté que l'entraînement du modèle pendant 20 époques nécessitait environ 7 heures de temps de calcul complet sur Google Colab. Cependant, cette durée d'entraînement plus longue a donné de meilleurs résultats en termes d'exactitude accrue et de perte réduite.

5. Métriques d'évaluation

Les métriques d'évaluation sont utilisées pour mesurer la performance d'un modèle de classification. Parmi ces métriques, on retrouve la précision, le rappel et le score F1.

5.1 L'accuracy

L'accuracy d'un instrument de mesure évalue sa précision dans la production de résultats proches de la valeur réelle. En classification, elle mesure le nombre de prédictions correctes sur l'ensemble total des prédictions. C'est une mesure de la justesse des prédictions du modèle.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FN + FP}$$

- TP (Vrais positifs) : nombre d'instances positives correctement prédites.
- TN (Vrais négatifs) : nombre d'instances négatives correctement prédites.
- FN (Faux négatifs) : nombre d'instances positives incorrectement prédites comme négatives.
- FP (Faux positifs) : nombre d'instances négatives incorrectement prédites comme positives.

5.2 Précision

La précision mesure l'exactitude du modèle dans la classification des échantillons positifs. Elle est calculée en divisant les vrais positifs par le nombre total d'échantillons classés comme positifs.

$$\text{Précision} = \frac{TP}{TP + FP}$$

5.3 Recall

Le rappel mesure la capacité du modèle à détecter correctement les exemples positifs. Il est calculé en divisant les vrais positifs par la somme des vrais positifs et des faux négatifs.

$$\text{Recall} = \frac{TP}{TP + FN}$$

5.4 F1-score

Le score F1 combine précision et rappel, évaluant ainsi la performance globale du modèle en minimisant les erreurs de classification. Un score élevé indique une bonne performance, tandis qu'un score faible indique des erreurs importantes.

$$F - score = 2 \times \frac{\text{précision} \times \text{recall}}{\text{précision} + \text{recall}}$$

6. Le Résultats

Selon le graphique présenté, après avoir fixé nos paramètres d'apprentissage de la meilleure manière possible, nous avons obtenu les résultats les plus satisfaisants. Ce graphique représente notre meilleure performance dans la reconnaissance de la langue des signes, démontrant ainsi l'efficacité de notre approche.




Figure 28 : Précision et Perte du modèle de Reconnaissance des Gestes des Mains

Les courbes de précision et de perte tracent l'évolution de la performance du modèle Resnet50v2 au fil des époques. Selon ces courbes, nous avons obtenu une précision de 95% sur les données de test, ce qui indique de bonnes performances. La précision de validation se maintient à un niveau satisfaisant, ce qui témoigne de la robustesse du modèle. Avant d'évaluer le modèle sur l'ensemble de tests, nous examinons la matrice de confusion des données d'apprentissage pour vérifier s'il y a des erreurs de prédiction. Ces résultats nous donnent de bonnes attentes quant aux performances du modèle sur l'ensemble de tests.

La matrice de confusion normalisée met en évidence la capacité du modèle à détecter les échantillons positifs. La plupart des échantillons positifs sont correctement prédits, à l'exception des classes "mute" et "ok".




Figure 29 : Matrix de confusion

Le tableau ci-dessous présente les mesures de classification du modèle, notamment la précision, le rappel, le score F1 et l'exactitude (accuracy) :

Tableau 4 : Performance de classification du modèle de détection de hand sign

	Précision	Recall	F1-score	Accuracy
Call	0.42	0.45	0.44	0.83

Mute	1	0.02	0.04	0.97
Ok	0.44	0.26	0.33	0.82
Palm	0.71	0.81	0.75	0.86
Peace	0.38	0.39	0.38	0.80
Stop	0.70	0.63	0.67	0.92

7. Conclusion

Dans ce chapitre, nous avons exploité un modèle pré-entraîné basé sur les CNN pour reconnaître les gestes des mains. Nos résultats mettent en évidence l'importance du nombre d'époques, de la taille de la base de données et de la complexité du réseau pour obtenir les meilleures performances possibles.

Chapitre 3

Développement pratique d'un système de reconnaissance des signes de la main

1 Introduction

Dans la dernière section de notre projet, nous aborderons la mise en œuvre concrète de notre travail. Pour commencer, nous procéderons à la configuration de la carte Raspberry, en nous concentrant sur l'environnement matériel utilisé. Nous détaillerons ensuite notre méthodologie d'implémentation des modèles que nous avons développés, en mettant l'accent sur les différentes étapes de notre approche. Par la suite, nous procéderons à l'évaluation et aux tests des résultats obtenus, afin d'analyser la performance de nos modèles et d'évaluer leur adéquation par rapport aux objectifs fixés. Enfin, nous clôturerons ce chapitre par une conclusion qui récapitulera les principales découvertes et les perspectives futures de notre projet.

2 Environnement matérielle utilisé

Nous avons utilisé les matérielles suivantes (caméra, carte Raspberry pi 4, Pc, câble Ethernet, chargeur) Voir la figure ci-dessous :



Figure 30 : Matérielles utilisés

2.1 Carte Raspberry pi 4

Le Raspberry Pi est un nano-ordinateur de la taille d'une carte de crédit qui peut être connecté à un écran et utilisé comme un ordinateur standard. Sa petite taille et son prix abordable en font un produit idéal pour expérimenter différentes applications, notamment la création d'un serveur Web à domicile. Il est équipé de plusieurs ports USB, un port Ethernet, un emplacement pour

une carte micro SD (où le système d'exploitation est généralement installé) et un port HDMI, entre autres caractéristiques.[12] Voir la figure ci-dessous :



Figure 31 : Carte Raspberry pi 4

Généralement, le Raspberry Pi fonctionne avec un système d'exploitation de type GNU/Linux, et la distribution la plus couramment utilisée est Raspbian. Raspbian est un système d'exploitation libre basé sur Debian, spécialement optimisé pour la carte Raspberry. Pour installer le système d'exploitation sur la carte, vous devrez utiliser un ordinateur Windows et plusieurs applications.

2.2 L'architecture interne de carte Raspberry

La figure ci-dessous représente l'architecture interne de la carte Raspberry pi 4 :




Figure 32 : l'architecture interne de la carte Raspberry pi 4

Et par la suite, j'ai présenté les caractéristiques de carte Raspberry pi 4 comme le tableau suivante :

Tableau 6 : les caractéristiques de Raspberry pi 4

Caractéristiques	Désignations	
Carte mère	Raspberry Pi 4	
Processeur	Broadcom BCM2711, quad-core Cortex-A72 (ARM v8) 64-bit SoC @ 1.5GHz	
RAM	8 Go LPDDR4	
GPU	Video Core VI prenant en charge OpenGL ES 3.0, décodage HEVC 4K à 60 i/s	
Connexion sans fil	Bluetooth 5.0, Wi-Fi 802.11b/g/n/ac	
Connexion filaire	Gigabit Ethernet (RJ45)	
Poids	40 g	
Port caméra	CSI pour connecter la caméra Raspberry Pi	
Port d'affichage	DSI pour connecter l'écran tactile Raspberry Pi	
Audio	AV 3.5 mm	
Ports	2 x USB 3.0 / 2 x USB 2.0 / 1 x USB-C (alimentation seulement) / 1 x GPIO 40 pin / 1 x port quadripôle Audio/Vidéo composite / 2 x micro-HDMI	
Alimentation	5V DC via un connecteur USB-C (minimum 3A), 5V DC via un entête GPIO (minimum 3A), compatible Power over Ethernet (PoE) (nécessite un HAT pour PoE)	
Dimensions	85,60 mm × 56,5 mm × 11 mm	

2.3 premier démarrage de Raspberry

Pour démarrer la carte, nous devons d'abord installer Raspbian sur la carte micro SD, puis passer par la configuration de Raspbian. Ensuite, dans la deuxième étape, nous activons SSH (Secure Shell) et définissons un nom d'utilisateur (pi) et un mot de passe (pi) pour la carte. Et dans la troisième étape, nous écrivons le système d'exploitation et constatons qu'il est installé avec succès. Pour mieux comprendre le sujet, dirigeons notre attention vers la Figure [33]



Figure 33 : Raspberry pi Imager

Créer un document sous le nom de ssh sans extension

start4cd.elf	31/03/2022 19:40	Fichier ELF	783 Ko
start4db.elf	31/03/2022 19:40	Fichier ELF	3 652 Ko
start4x.elf	31/03/2022 19:40	Fichier ELF	2 924 Ko
ssh	11/05/2022 23:43	Fichier	0 Ko

Figure 34 : L'ajout de ssh

Puis ajouter IP de la carte Raspberry dans le document Cmdline




Figure 35 : L'ajout de IP du Raspberry

Changer IP de Ethernet




Figure 36 : L'ajout de IP de Ethernet

Après avoir terminé l'installation du système d'exploitation, retirez la carte micro SD de l'ordinateur et insérez-la dans la Raspberry Pi 4. Assurez-vous également de connecter le câble Ethernet et le chargeur conformément à l'illustration ci-dessous :



Figure 37 : Branchement de carte Raspberry

Pour commencer, téléchargez le logiciel Putty. Une fois que nous l'avons installé, nous l'ouvrons et saisissons l'adresse IP de notre carte Raspberry Pi que nous avons obtenue à partir de Raspbian. Cela nous permettra d'établir une connexion à distance avec notre Raspberry Pi.




Figure 37 : L'interface de Putty

Pour continuer, nous allons télécharger VNC Viewer. Une fois le téléchargement terminé, ouvrons le logiciel et saisissons l'adresse IP de notre carte Raspberry Pi, ainsi que le nom d'utilisateur et le mot de passe associés. Cela nous permettra d'établir une connexion à distance avec notre Raspberry Pi en utilisant VNC Viewer.




Figure 38 : L'interface de VNC Viewer

Nous pouvons donc utiliser la carte Raspberry Pi pour nos besoins.

2.4 Caméra USB

La caméra est un élément fondamental et incontournable pour mettre en place notre système de vision dans ce projet. La caméra USB, spécialement conçue pour être utilisée avec la carte Raspberry Pi, a joué un rôle essentiel dans la reconnaissance des gestes des mains. Grâce à ce périphérique, nous avons pu capturer et analyser les mouvements des mains, permettant ainsi d'obtenir des résultats précis et fiables. Avant de passer à l'étape suivante, concentrons-nous sur la Figure [39]



Figure 39 : Camera

3 Réalisation réelle

Dans le cadre de notre projet, nous avons créé un dossier nommé "Test" dans la carte qui contient le modèle sous le format .h5, ainsi qu'un code permettant d'effectuer la reconnaissance de gestes en temps réel à l'aide d'une caméra vidéo. Voici un aperçu des principales étapes du fonctionnement :

- Configuration de la caméra : Nous avons configuré la caméra en spécifiant la résolution souhaitée et en ajustant la luminosité pour obtenir des résultats optimaux.

- **Chargement du modèle :** Nous avons chargé le modèle préalablement entraîné à partir du fichier .h5, ce qui nous permet d'utiliser ses connaissances pour la reconnaissance des gestes.
- **Prétraitement de l'image :** Avant de passer l'image capturée à travers le modèle, nous avons effectué un prétraitement. Cela comprend notamment le redimensionnement de l'image pour correspondre aux dimensions requises par le modèle, ainsi que la normalisation des valeurs des pixels.
- **Prédiction de l'image :** L'image prétraitée est ensuite soumise au modèle, qui génère des prédictions sur la classe de geste correspondante. Ces prédictions nous permettent de déterminer le geste effectué par l'utilisateur.
- **Affichage des résultats :** Les résultats de la prédiction sont affichés à l'écran en superposant le nom de la classe de geste détectée ainsi que la probabilité associée. Cela permet à l'utilisateur de visualiser instantanément le geste reconnu.
- **Boucle de traitement en temps réel :** Tout ce processus est réalisé en boucle, ce qui signifie que la caméra capture continuellement des images, les prétraite, les soumet au modèle pour prédiction, et affiche les résultats en temps réel. Cette boucle se poursuit jusqu'à ce que l'utilisateur décide d'arrêter l'application.
- **Libération des ressources :** Une fois l'utilisation terminée, nous libérons les ressources en refermant la connexion avec la caméra et en fermant toutes les fenêtres d'affichage.

Grâce à ce code, nous sommes en mesure d'effectuer une reconnaissance de gestes en temps réel, offrant ainsi une interface interactive et pratique pour interagir avec le système. La Figure [40] constitue une ressource visuelle essentielle pour comprendre [les gestes].




Figure 40 : Test de reconnaissance des gestes

Nous avons développé une interface graphique pour un système de reconnaissance des signes de la main. Cette interface permet de fournir des images de signes de la main et d'obtenir les mots correspondants à chaque signe détecté. Le système analyse les images et utilise des algorithmes de traitement pour reconnaître les différents signes de la main présents. Les résultats de la reconnaissance des signes sont affichés dans l'interface sous forme de mots écrits et peuvent également être prononcés vocalement. Cette double présentation des mots permet une meilleure compréhension et offre une communication plus complète et accessible.

4 Conclusion

En conclusion, ce chapitre a abordé différentes étapes clés, allant de l'installation de la carte Raspberry Pi à l'utilisation de Raspberry Pi Imager et VNC Viewer pour la configuration initiale. Nous avons ensuite procédé à l'implémentation de nos modèles de reconnaissance des gestes des mains, basés sur les CNN, en mettant l'accent sur la validation en temps réel. Enfin, nous avons minutieusement évalué les performances de nos modèles pour en tirer des conclusions significatives sur leur efficacité et leur potentiel d'application.

Conclusion générale

Ce projet de fin d'études revêt une grande importance dans le domaine de la reconnaissance des gestes en langue des signes. Notre objectif principal était de mettre au point un algorithme efficace en utilisant l'architecture des CNN combinée à l'analyse en composante principale.

Au cours de ce projet, nous avons également mis en place une infrastructure basée sur un environnement GPU et la carte Raspberry Pi 4 pour optimiser les performances et faciliter l'intégration du modèle de détection des gestes. Cela nous a permis de développer une application pratique et portable, ouvrant ainsi la voie à des utilisations thérapeutiques et éducatives auprès des personnes en situation de handicap.

En conclusion, ce projet de fin d'études nous a permis d'approfondir nos connaissances en matière de reconnaissance des gestes en langue des signes et d'appliquer les principes théoriques dans un contexte pratique. Nous sommes convaincus que cette technologie a un potentiel énorme pour améliorer l'apprentissage et faciliter la communication pour tous, en offrant des opportunités égales à chacun, quels que soient ses différences et ses handicaps. Ce travail marque le début d'un parcours prometteur dans le domaine de l'innovation technologique pour le bien-être et l'inclusion de tous.

Bibliographie :

- [1] Garg, Pradeep Kumar. "Overview of Artificial Intelligence." *Artificial Intelligence*. Chapman and Hall/CRC, 2021. 3-18.
- [2] BOILEAU, Justin-Éric, et al. "Rapport sur l'épistémologie de l'intelligence artificielle (IA)." (2022).
- [3] Singh, Navdeep, and Hiteshwari Sabrol. "Convolutional neural networks-an extensive arena of deep learning. A comprehensive study." *Archives of Computational Methods in Engineering* 28.7 (2021): 4755-4780.
- [4] Singu, Samrajyam. "Comparative Analysis of Artificial Neural Networks." *International Journal of Machine Learning for Sustainable Development* 3.4 (2021).
- [5] Kubat, Miroslav, and Miroslav Kubat. "Artificial neural networks." *An Introduction to Machine Learning* (2021): 117-143.
- [6] Kattenborn, Teja, et al. "Review on Convolutional Neural Networks (CNN) in vegetation remote sensing." *ISPRS journal of photogrammetry and remote sensing* 173 (2021).
- [7] Sakib, Shadman, et al. "An overview of convolutional neural network: its architecture and applications \ Convolution Layer." (2019).
- [8] Agarap, Abien Fred. "Deep learning using rectified linear units (relu)." *arXiv preprint arXiv:1803.08375* (2018).
- [9] Sakib, Shadman, et al. "An overview of convolutional neural network: its architecture and applications.\ Pooling Layer " (2019).
- [10] Li, Zhi, et al. "Teeth category classification via seven-layer deep convolutional neural network with max pooling and global average pooling." *International Journal of Imaging Systems and Technology* 29.4 (2019): 577-583.
- [11] Xu, Qi, et al. "Overfitting remedy by sparsifying regularization on fully-connected layers of CNNs." *Neurocomputing* 328 (2019): 69-74.
- [12] Raspberry Pi Foundation. (Consulté le 19 mai 2023). "Raspberry Pi." Disponible sur : <https://www.raspberrypi.org/>